StatsKurs_Uebung_Tag2

November 18, 2019

1 Einführung in die Statistik mit Python - Tag 2

1.1 Statistische Berechnungen mit Python

```
In [1]: # Import libraries
    import numpy as np
    import pandas as pd
    import matplotlib.pyplot as plt
    import seaborn as sns

# Was kann das Pandas package?
    # ?pd

# Zur Übersicht von verfügbaren Funktionen innerhalb der am häufigsten verwendeten Lib
    # geht oben im Menü auf Help
    # Hier gibt es Links zu der Übersicht der Packages: pandas, Matplotlib, NumPy, ...
```

1.1.1 Mittelwert berechnen

1.1.2 Median berechnen

```
if n % 2 == 0:
            lower = array[index - 1]
            upper = array[index]
            median = 0.5 * (lower + upper)
          else:
            median = array[index]
          return median
        gehalt = [1000, 1500, 1500, 20000, 3000, 2000]
        median(gehalt)
Out[3]: 1750.0
1.1.3 Modus berechnen
In [4]: from collections import Counter
        # Funktion definieren
        def modus(array):
          counts = Counter(array)
          most_common = counts.most_common(2)
          modus = most_common[0][1]
          if modus == most_common[1][1]:
            return None
          return array[modus]
        gehalt = [1000, 1500, 1500, 20000, 3000, 2000]
        modus(gehalt)
        from collections import Counter
        # Was für Funktionen gibt es noch im collections Paket?
        # import collections
        # ?collections
1.1.4 Quantile, Quartile and Perzentile
In [5]: # Import library for iris dataset
        import seaborn as sns
        # Import dataset
        iris = sns.load_dataset('iris')
        # Look at head of iris dataset
        iris.head()
        # Quantile of all numeric variables
        iris.quantile([0.01, 0.25, 0.5, 0.75, 0.99])
```

```
# Quantile of one numeric variable (here: sepal_length)
        iris["sepal_length"].quantile([0, 0.25, 0.5, 0.75, 1])
        # Quantile von Gehalt, die Liste muss zuerst in DataFrame umgewandelt werden
        gehalt = pd.DataFrame([1000, 1500, 1500, 20000, 3000, 2000])
        gehalt.quantile([0.01, 0.25, 0.5, 0.75, 0.99])
Out[5]:
                    0
        0.01
               1025.0
        0.25
              1500.0
        0.50
               1750.0
        0.75
               2750.0
        0.99 19150.0
1.1.5 Five-number summary
In [6]: def fivenum(data):
          return np.percentile(data, [0, 25, 50, 75, 100], interpolation='midpoint')
       moons = [0, 0, 1, 2, 63, 61, 27, 13]
       print(fivenum(moons))
Γ0.
      0.5 7.5 44. 63. 1
1.1.6 Extremwerte und Spannweite
In [7]: values = [4,12,43.3,19,100]
       print(min(values)) # Calculate minimum
       print(max(values)) # Calculate maximum
        # Die Funktion range() berechnet nicht die Spannweite,
        # sondern wirft Zahlen in einer bestimmten Spanne aus
        range(5)
        # Daher muessen wir hierfür eine neue Funktion definieren
        def getrange(numbers): return max(numbers) - min(numbers)
       print(getrange(values)) # Calculate range
4
100
```

96

1.1.7 Varianz berechnen

```
In [8]: import math
        def varianz(array):
          n = len(array)
          mn = sum(array) / n
          var = (1 / (n-1)) * sum(map(lambda xi: (xi-mn) ** 2 , array))
        gehalt = [1000, 1500, 1500, 20000, 3000, 2000]
        varianz(gehalt)
Out [8]: 55666666.6666668
1.1.8 Standardabweichung berechnen
In [9]: def standard_abweichung(array):
          n = len(array)
          mn = sum(array) / n
          var = (1 / (n-1)) * sum(map(lambda xi: (xi-mn) ** 2 , array))
          std = math.sqrt(var)
          return std
        gehalt = [1000, 1500, 1500, 20000, 3000, 2000]
        standard_abweichung(gehalt)
Out[9]: 7461.009761866465
1.1.9 Berechnung des Variationskoeffizienten
In [10]: def var_koeff(array):
           n = len(array)
           mn = sum(array) / n
           var = (1 / (n-1)) * sum(map(lambda x: (x - mn) ** 2 , array))
           std = math.sqrt(var)
           cv = std / mn
           if 0 in array:
             cv = cv / math.sqrt((n-1))
           return cv
         pizza_de = [4.99, 7.99, 5.99, 4.99, 6.99]
         var_koeff(pizza_de)
Out[10]: 0.21063658821333273
1.1.10 Ein Gesamtüberblick
In [11]: # Import dataset
         iris.describe()
```

```
Out[11]:
                sepal_length
                              sepal_width petal_length petal_width
                  150.000000
                               150.000000
                                              150.000000
                                                           150.000000
         count
                    5.843333
                                 3.057333
                                                3.758000
                                                             1.199333
         mean
                    0.828066
                                 0.435866
                                                1.765298
                                                             0.762238
         std
         min
                    4.300000
                                 2.000000
                                                1.000000
                                                             0.100000
         25%
                                 2.800000
                                                1.600000
                                                             0.300000
                    5.100000
         50%
                    5.800000
                                 3.000000
                                                4.350000
                                                             1.300000
         75%
                    6.400000
                                 3.300000
                                                5.100000
                                                             1.800000
                    7.900000
                                 4.400000
                                                6.900000
                                                             2.500000
         max
```

1.1.11 Daten einzeln zusammenfassen

1.1.12 Daten aggregiert zusammenfassen

1.1.13 Skewness und Kurtosis

```
In [14]: # Import kurtosis and skewness functions
    from scipy.stats import kurtosis
    from scipy.stats import skew

# Create data
    data = np.random.normal(0, 1, 10000000)

# Calculate skewness and kurtosis
    print("skew : ",skew(data))
    print("kurt : ",kurtosis(data))
```

skew: -0.0006041003961050831 kurt: 0.0003287467593784399

1.1.14 Daten als Tabelle

```
In [15]: # Filtering iris data
         speciesdf = iris["species"]
         # Group by species
         speciesdf = pd.DataFrame(speciesdf.value_counts(sort=True))
         # Create new column with cumulative sum
         speciesdf["cum_sum"] = speciesdf["species"].cumsum()
         # Create new column with relative frequency
         speciesdf["cum_perc"] = 100*speciesdf["cum_sum"]/speciesdf["species"].sum()
         speciesdf
Out [15]:
                     species cum_sum
                                        cum_perc
         setosa
                          50
                                   50
                                        33.333333
         virginica
                          50
                                  100
                                        66.666667
         versicolor
                                  150 100.000000
                          50
```

1.1.15 Aufteilung in Intervalle und entsprechende Häufigkeiten

1.1.16 Do it yourself

Liest erneut den Datensatz size.csv in Python ein

```
In [17]: size = pd.read_csv("/home/matt/Documents/Github/pyStats/data/size.csv")
```

Berechnet die Minimal-, Durchschnitts- und MaximalgröSSe jeweils für Männer und für Frauen

```
In [18]: size_m = size[(size.geschlecht == "m")]
         size_w = size[(size.geschlecht == "w")]
         size_m.min(); size_w.min()
         size m.mean(); size w.mean()
         size_m.max(); size_w.min()
Out[18]: geschlecht
         groesse_cm
                         160
         schuhgroesse
                           36
         teilnehmer
                            0
         dtype: object
   Wie viele Dateneinträge gibt es jeweils für Männer und für Frauen (Kontingenztafel)
In [19]: # Filtering data
         size_sex = size["geschlecht"]
         # Group by species
         size_sex = pd.DataFrame(size_sex.value_counts(sort=True))
         # Create new column with cumulative sum
         size_sex["cum_sum"] = size_sex["geschlecht"].cumsum()
         # Create new column with relative frequency
         size_sex["cum_perc"] = 100*size_sex["cum_sum"]/size_sex["geschlecht"].sum()
         size_sex
Out[19]:
            geschlecht cum_sum
                                    cum_perc
                    16
                              16
                                   53.333333
         m
                    14
                              30 100.000000
   Berechnet Minimum, unteres Quartil, Median, oberes Quartile und Maximum der Schuh-
groessen
In [20]: size["schuhgroesse"].describe
Out[20]: <bound method NDFrame.describe of 0
                                                  43
         1
         2
               41
         3
               38
         4
               39
         5
               46
         6
               43
         7
               41
         8
               39
         9
               37
         10
               40
```

11

43

```
42
12
13
      39
14
      43
15
      37
16
      39
17
      45
18
      46
19
      40
20
      36
21
      40
22
      38
23
      42
24
      43
25
      45
26
      42
27
      39
28
      46
29
      39
Name: schuhgroesse, dtype: int64>
```

Gibt es eine stärkere Varianz und Standardabweichung in der Schuhgroesse von Männern oder von Frauen?

1.2 Datenvisualisierung mit Python

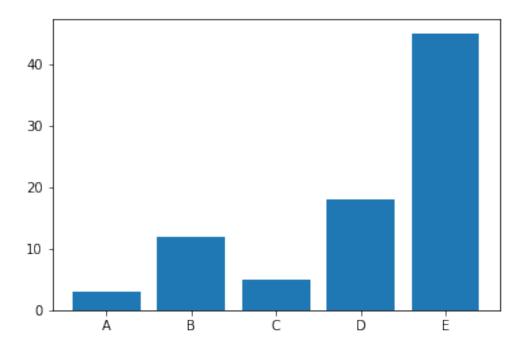
1.2.1 Säulendiagramm

```
In [22]: # Make a fake dataset:
    height = [3, 12, 5, 18, 45]
    bars = ('A', 'B', 'C', 'D', 'E')
    y_pos = np.arange(len(bars))

# Create bars
    plt.bar(y_pos, height)

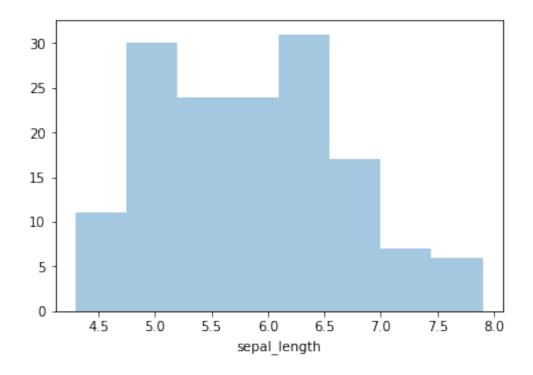
# Create names on the x-axis
    plt.xticks(y_pos, bars)

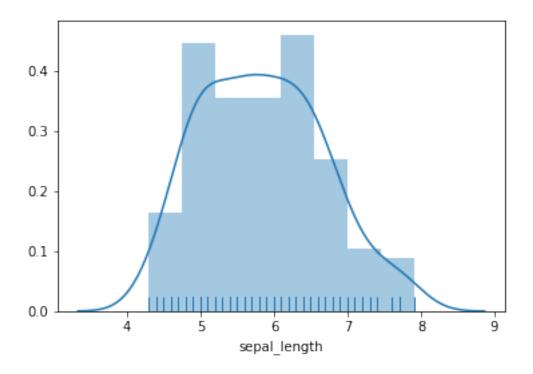
plt.show() # Show graphic
```

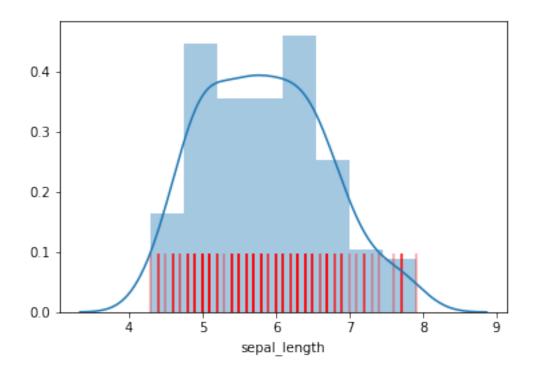


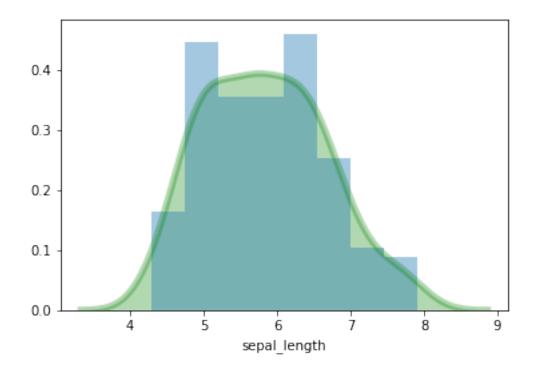
1.2.2 Histogramm

```
In [23]: # Import library and dataset
         iris = sns.load_dataset('iris')
         # Hist only
         sns.distplot(a=iris["sepal_length"], hist=True, kde=False, rug=False )
        plt.show()
         # Hist + Rug + kernel density
         sns.distplot( a=iris["sepal_length"], hist=True, kde=True, rug=True )
         plt.show()
         # To change parameters of rug
         sns.distplot( a=iris["sepal_length"], rug=True,
         rug_kws={"color": "r", "alpha":0.3, "linewidth": 2, "height":0.2 }
         plt.show()
         # To change parameters of density distribution
         sns.distplot( a=iris["sepal_length"], kde=True,
         kde_kws={"color": "g", "alpha":0.3, "linewidth": 5, "shade":True }
         )
        plt.show()
```

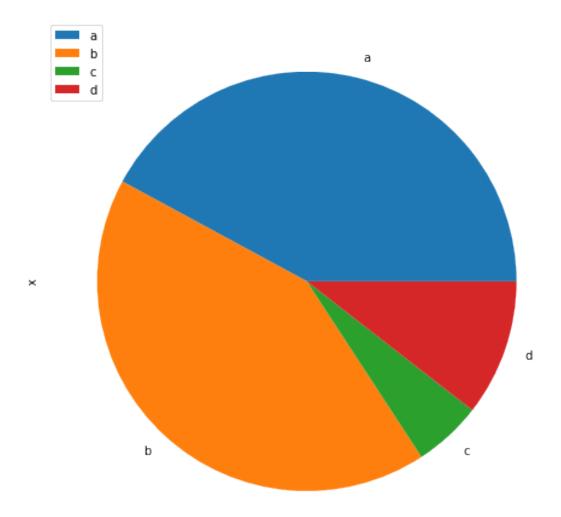








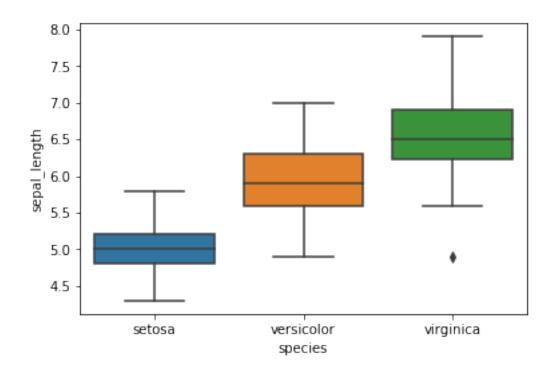
1.2.3 Kuchen-Diagramm

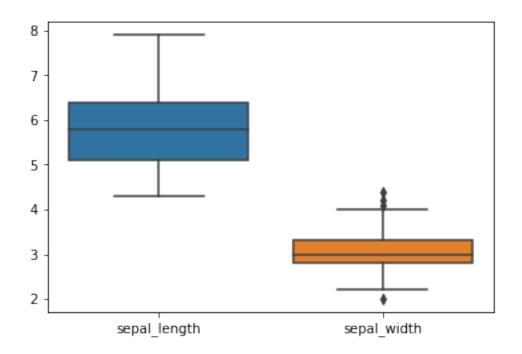


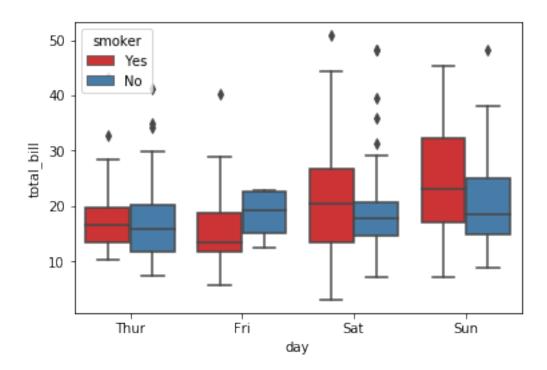
1.2.4 Box-Plot

```
In [25]: iris = sns.load_dataset('iris')
```

```
# Make boxplot for one group only
 sns.boxplot(y=iris["sepal_length"])
 plt.show()
 sns.boxplot(x=iris["species"], y=iris["sepal_length"])
 plt.show()
 sns.boxplot(data=iris.iloc[:,0:2])
 plt.show()
 # Grouped boxplot
 tips = sns.load_dataset('tips')
 sns.boxplot(x="day", y="total_bill", hue="smoker", data=tips, palette="Set1")
 plt.show()
   8.0
   7.5
   7.0
sepal_length
6.0
5.5
   5.5
   5.0
   4.5
```



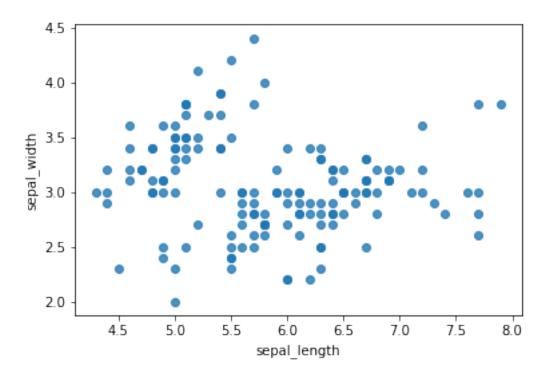




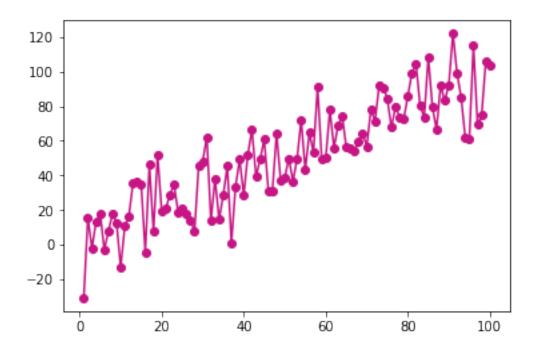
1.2.5 Streudiagramm

```
In [26]: iris = sns.load_dataset('iris')

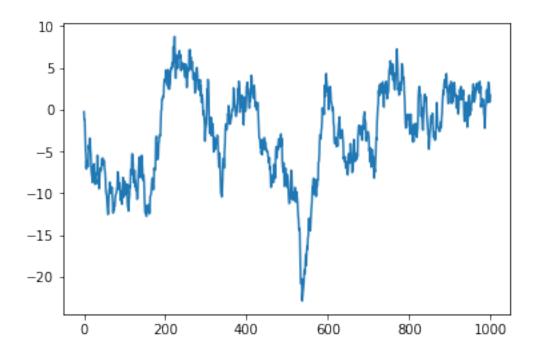
# use the function regplot to make a scatterplot
sns.regplot(x=iris["sepal_length"], y=iris["sepal_width"], fit_reg=False)
plt.show()
```



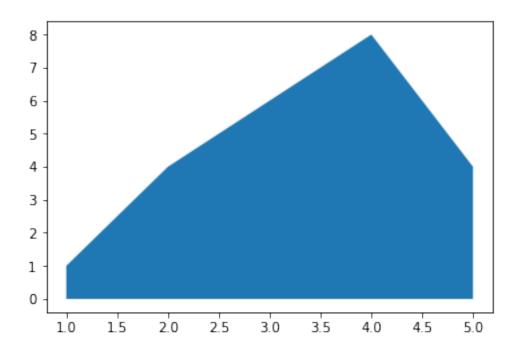
1.2.6 Verbundenes Streudiagramm



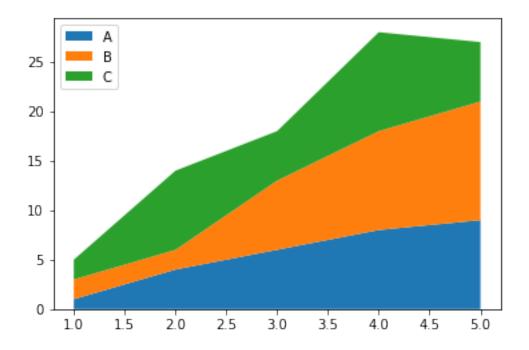
1.2.7 Liniendiagramm



1.2.8 Flächendiagramm

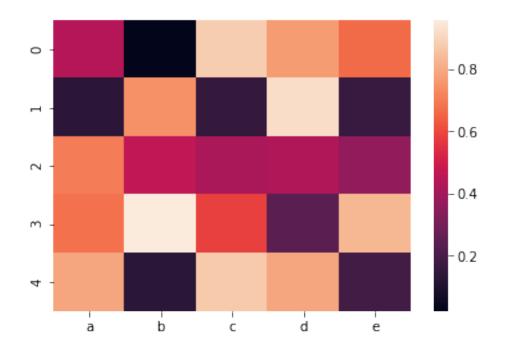


1.2.9 gestapeltes Flächendiagramm



1.2.10 Heatmap

Out[31]: <matplotlib.axes._subplots.AxesSubplot at 0x7f367d458048>



1.2.11 Grafiken speichern

```
In [32]: # Um Grafiken am richtigen Ort zu speichern, muss man den kompletten Pfad angeben
#plt.savefig('/home/matt/Desktop/StatsKurs/plot1.png')
#plt.savefig('/home/matt/Desktop/StatsKurs/plot1.pdf')

# Ansonsten werden die Grafiken im derzeitigen Arbeits-Verzeichnis gespeichert

# Diese lässt sich so abrufen
import os
print(os.getcwd())

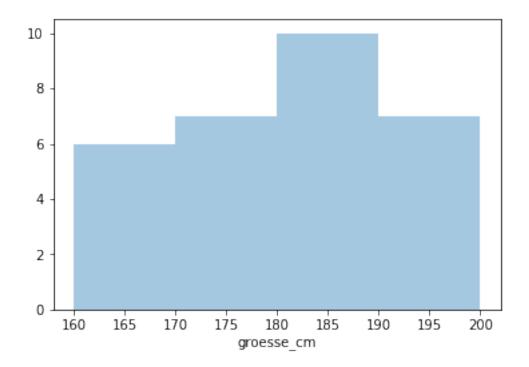
# und mit os.chdir() einem bestimmten Pfad zu weisen
os.chdir('/home/matt/Documents/Github/pyStats')
```

/home/matt/Documents/Github/pyStats

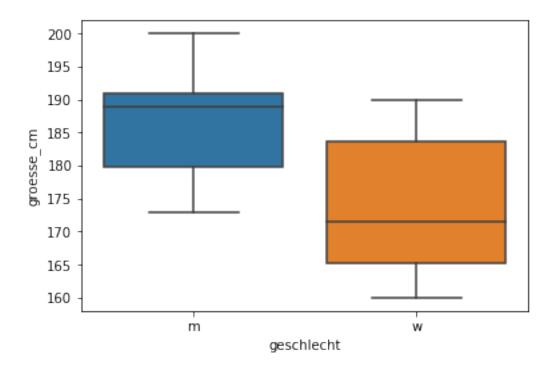
1.2.12 Do it yourself

Liest erneut den Datensatz size.csv in Python ein

Erstellt einen geeignete Grafik um die Groesse darzustellen



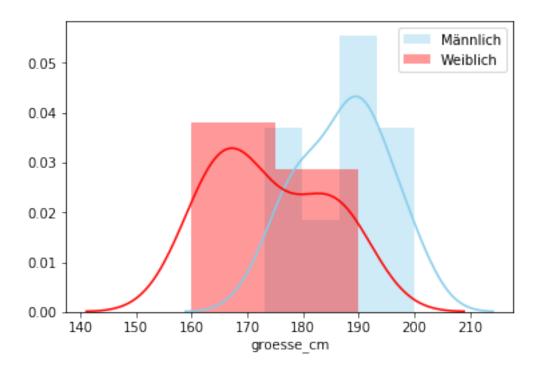
Plottet die Groesse in Zusammenhang zum Geschlecht



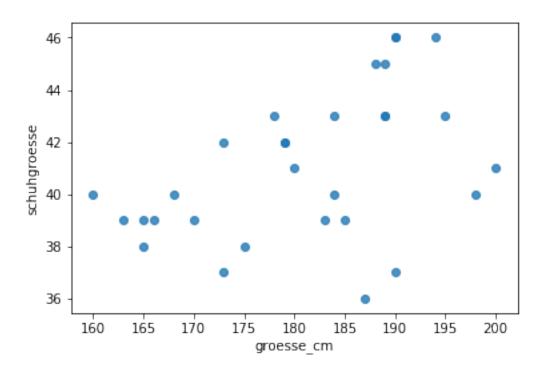
```
In [36]: # Oder zwei Histogramme in einem Plot
    size_m = size[(size.geschlecht == "m")]
    size_w = size[(size.geschlecht == "w")]

sns.distplot(size_m["groesse_cm"] , color="skyblue", label="Männlich")
    sns.distplot(size_w["groesse_cm"] , color="red", label="Weiblich")
    plt.legend()
```

Out[36]: <matplotlib.legend.Legend at 0x7f3678ea97f0>



Plottet die SchuhgröSSe gegen die Körpergroesse



Speichert die erstellten Grafiken als Datei

